

PROJET DE FIN D'ÉTUDES — PLATEFORME SENIORS

Veille Technologique et Intelligence Artificielle

LLM · RAG · IA Agentique · IA Prédictive · IA Décisionnelle

Thématique	Technologies couvertes
Grands Modèles de Langage (LLM)	GPT-4o, Claude 3, Gemini, LLaMA 3, Mistral, Falcon
(RAG) :Retrieval-Augmented Generation	Architectures RAG, bases vectorielles, chunking, re-ranking
IA Agentique	Agents autonomes, Multi-Agent Systems, ReAct, AutoGPT, LangGraph
IA Prédictive	Machine Learning, systèmes de recommandation, détection d'anomalies
Application au projet SENIORS	Matching intergénérationnel, chatbot, détection d'isolement

INTRODUCTION : CONTEXTE ET OBJECTIFS DE LA VEILLE

La présente veille technologique s'inscrit dans le cadre du projet de fin d'études portant sur la conception et le développement de la plateforme SENIORS — une application numérique dédiée aux personnes retraitées et pré-retraitées. Elle vise à dresser un état de l'art rigoureux et actualisé des technologies d'intelligence artificielle les plus pertinentes pour ce projet, en couvrant quatre grands domaines : les Grands Modèles de Langage (LLM), la Retrieval-Augmented Generation (RAG), l'IA agentique et l'IA prédictive et décisionnelle.

L'objectif de cette veille est double. Premièrement, il s'agit de fournir au lecteur les fondements scientifiques et techniques nécessaires à la compréhension des technologies retenues, en les situant dans leur contexte d'émergence et d'évolution. Deuxièmement, il s'agit d'évaluer le potentiel et les modalités d'intégration de chacune de ces technologies dans l'architecture de la plateforme SENIORS, en justifiant les choix technologiques opérés par l'équipe projet.

Cette veille adopte une approche systématique, croisant l'analyse de la littérature scientifique académique (articles publiés dans des conférences de référence telles que NeurIPS, ICML, ACL, EMNLP), des rapports techniques des principaux laboratoires de recherche en IA (OpenAI, Anthropic, Google DeepMind, Meta AI, Mistral AI), et des retours d'expérience documentés issus de déploiements industriels.

Partie I : Grands Modèles de Langage (LLM)

1. Fondements Scientifiques et Historique des LLM

Large Language Models (LLM) constituent aujourd'hui l'une des avancées les plus significatives de l'histoire de l'intelligence artificielle. Leur émergence résulte d'une convergence de trois facteurs déterminants : l'architecture Transformer, introduite par Vaswani et al. en 2017 dans l'article fondateur « Attention Is All You Need » ; la disponibilité de masses de données textuelles sans précédent ; et l'augmentation exponentielle de la puissance de calcul accessible aux chercheurs et aux entreprises.

1.1 L'architecture Transformer : fondement mathématique des LLM

L'architecture Transformer repose sur un mécanisme central appelé self-attention (auto-attention), qui permet au modèle de pondérer dynamiquement l'importance relative de chaque token d'une séquence par rapport à tous les autres tokens de cette même séquence. Formellement, le mécanisme d'attention est défini par l'équation suivante :

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \times V$$

où Q (Query), K (Key) et V (Value) sont des matrices de projections linéaires des embeddings d'entrée, et d_k est la dimension de la clé. Ce mécanisme permet de capturer des

dépendances à longue distance dans le texte, surpassant les architectures récurrentes (RNN, LSTM) qui peinaient à modéliser des contextes étendus.

1.2 Évolution des LLM : chronologie et jalons

Année	Modèle / Événement	Organisation	Paramètres	Innovation clé
2017	Architecture Transformer	Google Brain	—	Mécanisme d'attention, abandon des RNN
2018	BERT (Bidirectional Encoder)	Google	340 M	Pré-entraînement bidirectionnel, fine-tuning sur tâches NLP
2019	GPT-2	OpenAI	1,5 Md	Génération de texte cohérente, few-shot learning émergent
2020	GPT-3	OpenAI	175 Md	In-context learning, capacités générales sans fine-tuning
2021	PaLM, Chinchilla	Google, DeepMind	540 Md	Scaling laws, optimisation données/paramètres
2022	ChatGPT (GPT-3.5 + RLHF)	OpenAI	175 Md	RLHF, alignement aux préférences humaines, interface conversationnelle
2023	GPT-4, LLaMA 2, Claude 2, Mistral 7B	OpenAI, Meta, Anthropic, Mistral	Var.	Multimodalité, open-source performant, modèles compacts
2024	GPT-4o, Claude 3, Gemini 1.5, LLaMA 3	OpenAI, Anthropic, Google, Meta	Var.	Contextes longs (1M tokens), efficacité, raisonnement avancé
2025	Claude 3.5, Gemini 2, Mistral Large	Anthropic, Google, Mistral	Var.	IA agentique native, tool use, mémoire persistante

1.3 Le paradigme d'entraînement des LLM

L'entraînement des LLM suit un paradigme en trois phases successives et complémentaires :

Pré-entraînement (Pre-training) : La phase de pré-entraînement consiste à entraîner le modèle sur un corpus massif de textes (des centaines de milliards à des milliers de milliards de tokens) selon un objectif d'auto-supervision — typiquement la prédiction du prochain token (Next Token Prediction) pour les modèles décodeurs (GPT-like) ou la reconstruction de tokens masqués (Masked Language Modeling) pour les modèles encodeurs (BERT-like). Cette phase dote le modèle d'une représentation riche et générale du langage et du savoir humain.

Ajustement fin supervisé (SFT) : L'ajustement fin supervisé (Supervised Fine-Tuning, SFT) consiste à spécialiser le modèle pré-entraîné sur des exemples de conversations ou de tâches spécifiques annotés par des humains. Cette phase oriente les capacités générales du modèle vers des comportements et des formats de réponse souhaités.

Alignement par RLHF : Le Reinforcement Learning from Human Feedback (RLHF) constitue l'étape d'alignement aux préférences humaines. Un modèle de récompense (reward model) est entraîné sur des préférences humaines entre paires de réponses, puis utilisé pour optimiser le LLM via un algorithme de Proximal Policy Optimization (PPO). Cette phase est décisive pour rendre le modèle utile, inoffensif et honnête.

2. État de l'Art des Principaux Modèles LLM en 2024–2025

Le paysage des LLM en 2024–2025 se caractérise par une fragmentation en deux grandes catégories : les modèles propriétaires de haute performance, développés par de grandes entreprises technologiques, et les modèles open-source ou open-weight, dont la démocratisation constitue l'une des tendances majeures de la période.

2.1 Modèles propriétaires de référence

Modèle	Éditeur	Fenêtre contexte	Forces distinctives	Cas d'usage optimaux
GPT-4o	OpenAI	128 K tokens	Multimodalité native (texte, image, audio), vitesse, API mature et écosystème riche	Assistant conversationnel, analyse de documents complexes, génération de code
Claude 3.5 Sonnet	Anthropic	200 K tokens	Raisonnement long, alignement éthique robuste, following d'instructions précis, outil use avancé	Analyse de documents longs, tâches complexes multi-étapes, applications nécessitant fiabilité
Gemini 1.5 Pro	Google	1 M tokens	Fenêtre contextuelle extrêmement large, intégration native Google Workspace, multimodalité	Analyse de corpus entiers, vidéo, intégration d'outils Google
Mistral Large 2	Mistral AI	128 K tokens	Excellence sur le français et les langues latines, efficacité computationnelle, RGPD compliance européenne	Applications francophones, déploiement on-premise souverain, coût maîtrisé

2.2 Modèles open-source / open-weight de référence

Modèle	Éditeur	Paramètres	Licence	Avantages pour un projet académique
LLaMA 3.1 (8B, 70B, 405B)	Meta AI	8B à 405B	Meta Llama License (usage commercial possible)	Famille complète, excellent rapport performance/taille, fine-tuning facilité par LoRA/QLoRA
Mistral 7B / Mixtral 8x7B	Mistral AI	7B / 46B actifs	Apache 2.0	Architecture MoE (Mixture of Experts) pour Mixtral, très efficace, francophone
Qwen2.5 (7B à 72B)	Alibaba Cloud	7B à 72B	Apache 2.0	Multilingue (arabe inclus), fort en code, contexte long jusqu'à 128K
Gemma 2 (2B, 9B, 27B)	Google	2B à 27B	Gemma Terms of Use	Modèles compacts très performants, adapté aux déploiements sur ressources limitées
Phi-3 (Mini, Small, Medium)	Microsoft	3,8B à 14B	MIT	Modèles ultra-compacts pour déploiement edge/mobile, idéal pour assistant senior sur appareil

2.3 Techniques d'adaptation des LLM au domaine

Pour adapter un LLM pré-entraîné au domaine spécifique de la plateforme SENIORS, plusieurs techniques d'adaptation sont disponibles, présentant des compromis distincts entre performance, coût computationnel et volume de données requis :

- **Full Fine-Tuning** : Le fine-tuning complet consiste à réentraîner l'ensemble des paramètres du modèle sur des données du domaine cible. Cette approche maximise les performances mais exige des ressources computationnelles considérables (GPU A100 ou H100 multipliés) et des volumes de données importants. Elle est généralement hors de portée d'un projet académique.
- **LoRA (Low-Rank Adaptation)** : introduit par Hu et al. (2021), est une technique de fine-tuning paramètre-efficace qui n'entraîne que des matrices de faible rang ajoutées aux couches d'attention du modèle, gelant le reste des paramètres. LoRA permet de fine-tuner des modèles de 7 à 70 milliards de paramètres sur un GPU de 16 à 24 Go de VRAM, rendant l'adaptation accessible dans un cadre académique.
- **QLoRA (Quantized LoRA)** : développé par Dettmers et al. (2023), combine la quantification du modèle de base en 4 bits avec l'approche LoRA, permettant le fine-tuning de modèles de 65 milliards de paramètres sur un seul GPU de 48 Go. Cette technique constitue l'approche de référence pour l'adaptation de LLMs dans un contexte de ressources limitées.
- **Few-Shot Prompting et PEFT** : Le Few-Shot Prompting et l'instruction tuning via des techniques comme PEFT (Parameter-Efficient Fine-Tuning) permettent d'adapter les comportements du modèle sans modifier les poids, uniquement via l'ingénierie des prompts système et des exemples contextuels.

3. Application des LLM à la Plateforme SENIORS

Dans le contexte de la plateforme SENIORS, l'intégration de LLMs répond à plusieurs besoins fonctionnels identifiés lors de l'analyse des exigences. Le choix technologique retenu est d'adopter une architecture hybride, combinant un LLM open-source léger (LLaMA 3.1 8B ou Mistral 7B) pour les fonctions à faible latence, et une API propriétaire (Claude 3.5 ou GPT-4o) pour les tâches nécessitant un raisonnement plus élaboré.

Fonctionnalité SENIORS	Rôle du LLM	Modèle recommandé	Approche technique
Assistant conversationnel senior-friendly	Dialogue en langage naturel, guidage de l'utilisateur dans l'app, réponse aux questions fréquentes	Mistral 7B fine-tuné ou LLaMA 3.1 8B	RAG + fine-tuning LoRA sur corpus de conversations seniors
Génération d'annonces de location	Transformation d'informations brutes en description structurée et attractive	Claude 3.5 Sonnet (API) ou GPT-4o	Prompting structuré avec template et few-shot examples
Médiation et résolution de conflits	Suggestions de reformulations constructives, propositions de compromis	GPT-4o ou Claude 3.5	Chain-of-Thought prompting + génération contrainte
Interface vocale (accessibilité)	Transcription vocale (STT) et synthèse vocale (TTS) pour seniors malvoyants ou dyslexiques	Whisper (OpenAI) + TTS natif	Pipeline ASR → LLM → TTS intégré
Génération de contenu marketing	Rédaction de descriptions de services, réponses types, newsletters personnalisées	Mistral Large 2 (francophone)	Prompting métier + garde-fous de modération automatique

PARTIE II : RETRIEVAL-AUGMENTED GENERATION (RAG)

4. Fondements de la RAG : Définition et Architecture

La RAG est un paradigme architectural introduit par Lewis et al. (Meta AI Research, 2020) dans l'article « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». Ce paradigme répond à une limitation fondamentale des LLM purs : leur connaissance est figée au moment de leur entraînement (knowledge cutoff) et ne peut être mise à jour sans un réentraînement coûteux. La RAG combine dynamiquement la puissance générative des LLM avec un système de recherche d'informations en temps réel, permettant au modèle d'accéder à des connaissances à jour et spécifiques au domaine sans modification de ses poids.

Définition académique :

La RAG est un cadre d'architecture hybride qui enrichit le processus de génération d'un LLM par l'injection dynamique de passages informatifs pertinents extraits d'une base de connaissances externe, sélectionnés par similarité sémantique avec la requête de l'utilisateur.

Formellement : $P(y|x) = \sum_z P(y|x,z) \times P(z|x)$

où x est la requête, z est le document récupéré et y est la réponse générée.

4.1 Architecture d'un pipeline RAG standard

Un pipeline RAG standard se décompose en cinq étapes séquentielles :

- ✓ Étape 1 : Ingestion et indexation : La phase d'ingestion des documents constitue l'étape préliminaire hors ligne. Les documents de la base de connaissances (FAQ, réglementation locale, fiches de profils types, guides d'utilisation) sont chargés, segmentés en chunks (segments de taille optimale, typiquement 256 à 512 tokens avec overlap), puis transformés en vecteurs denses (embeddings) par un modèle d'embedding spécialisé (text-embedding-3-small d'OpenAI, ou sentence-transformers/paraphrase-multilingual-mpnet-base-v2 pour le multilinguisme). Les vecteurs sont stockés dans une base de données vectorielle.
- ✓ Étape 2 : Embedding de la requête et recherche : Lors d'une requête utilisateur, cette même requête est convertie en vecteur d'embedding par le même modèle utilisé lors de l'ingestion. Une recherche par similarité cosinus (ou produit scalaire) est effectuée dans la base vectorielle pour identifier les k chunks les plus sémantiquement proches de la requête (typiquement $k = 3$ à 10).
- ✓ Étape 3 : Re-ranking des résultats : Les chunks récupérés sont réordonnés selon leur pertinence réelle par un modèle de re-ranking (cross-encoder), plus précis que la simple similarité cosinus mais trop lent pour être utilisé en première passe. Des modèles comme Cohere Rerank ou ms-marco-MiniLM-L-6-v2 sont utilisés à cette fin.
- ✓ Étape 4 : Construction du prompt augmenté : Les chunks sélectionnés et réordonnés sont injectés dans le prompt du LLM, au sein d'un template structuré précisant le contexte, les documents récupérés et la question de l'utilisateur. Le LLM génère alors sa réponse en se basant à la fois sur ses connaissances intrinsèques et sur le contexte fourni.
- ✓ Étape 5 : Génération et vérification : La réponse générée peut être soumise à une étape de vérification de fidélité factuelle (faithfulness check), vérifiant que les affirmations de la réponse sont effectivement supportées par les documents récupérés. Des frameworks comme RAGAS permettent d'évaluer cette fidélité de manière automatisée.

4.2 Bases de données vectorielles : état de l'art

Solution	Type	Forces	Limitations	Adapté pour SENIORS
ChromaDB	Open-source, embarqué ou client-serveur	Très simple d'utilisation, gratuit, idéal pour prototypage, Python natif	Performances limitées à grande échelle	Oui , idéal pour prototype académique
FAISS (Facebook AI)	Bibliothèque open-source	Très performant, optimisé GPU, millions de vecteurs	Pas de gestion de métadonnées native, peu d'abstractions	Oui , pour usage local et performance
Pinecone	SaaS cloud managé	Scalable, API simple, filtrage par métadonnées, serverless	Coût selon volume, dépendance cloud	Possible , offre gratuite pour prototype
Qdrant	Open-source + SaaS	Filtrage avancé par payload, haute performance, Rust-based	Documentation moins abondante	Oui , bonne alternative open-source
Weaviate	Open-source + SaaS	Modules hybrides (dense + sparse), GraphQL, multimodalité	Complexité de configuration plus élevée	Possible , pour déploiements avancés

5. Architectures RAG Avancées

Au-delà du pipeline RAG standard, la recherche académique a proposé plusieurs architectures avancées qui améliorent significativement la qualité des réponses générées, au prix d'une complexité accrue :

5.1 Self-RAG

Self-RAG (Asai et al., 2023) est une architecture dans laquelle le LLM apprend à décider lui-même s'il a besoin de récupérer des informations supplémentaires pour répondre à une question (retrieval on demand), plutôt que de récupérer systématiquement des chunks. Le modèle génère des tokens spéciaux (critique tokens) pour signaler la nécessité de retrieval et évaluer la qualité des documents récupérés. Cette architecture améliore la précision et réduit les hallucinations.

5.2 HyDE (Hypothetical Document Embeddings)

HyDE (Gao et al., 2022) résout le problème de l'asymétrie sémantique entre la requête et les documents indexés. Plutôt que d'embedder directement la requête utilisateur (souvent courte et générale), le LLM génère d'abord un document hypothétique qui constituerait une réponse idéale à cette requête. Cet document hypothétique est ensuite utilisé comme vecteur de recherche, produisant des résultats de retrieval plus précis.

5.3 RAPTOR (Recursive Abstractive Processing for Tree-Organized Retrieval)

RAPTOR (Sarhi et al., 2024) adresse la limite des approches de chunking fixe en construisant une hiérarchie de résumés récurifs des documents. Les chunks leaf sont regroupés par clustering sémantique, puis résumés en chunks parent de niveau supérieur, créant un arbre de représentations à granularités multiples. Cette architecture améliore significativement les performances sur les questions nécessitant une compréhension multi-niveaux des documents.

6. Application de la RAG à la Plateforme SENIORS

Dans le contexte de la plateforme SENIORS, l'architecture RAG est particulièrement adaptée pour plusieurs raisons : la base de connaissances du domaine (réglementation locative marocaine, droits des seniors, guide d'utilisation de l'application, FAQ) est de taille gérable et peut être indexée intégralement ; les requêtes des utilisateurs seniors sont généralement factuelles et spécifiques ; et la nécessité de réponses précises et fondées sur des informations vérifiables prime sur la créativité générative pure.

Source de connaissances	Type de documents	Utilisation dans SENIORS
Base légale et réglementaire	Loi 09-08 (protection des données), code de la location marocain, droits des retraités	Réponses aux questions légales des utilisateurs sur leurs droits et obligations
FAQ et guides d'utilisation	Documentation de l'application, tutoriels, réponses aux questions fréquentes	Support utilisateur via chatbot, réduction des tickets de support humain
Profils et conditions de cohabitation	Templates de conditions de cohabitation, exemples de bonnes pratiques	Aide à la rédaction des conditions sociales dans les annonces
Informations sur les services disponibles	Catalogue des services proposés par les seniors sur l'espace marketing	Recommandation de services et réponses aux questions de recherche
Ressources de bien-être senior	Articles sur le vieillissement actif, activités recommandées, ressources locales	Enrichissement des conversations de l'assistant au-delà des sujets strictement transactionnels

Architecture RAG recommandée pour SENIORS : ChromaDB comme base vectorielle (gratuit, Python natif, adapté au prototype), paraphrase-multilingual-mpnet-base-v2 comme modèle d'embedding (multilingue français-arabe, gratuit, open-source), Mistral 7B comme LLM de génération (via Ollama pour déploiement local sans coût API), et un re-ranking par cross-encoder optionnel en phase de production.

PARTIE III — IA AGENTIQUE

7. Fondements de l'IA Agentique

L'intelligence artificielle agentique (Agentic AI) désigne des systèmes d'IA capables d'agir de manière autonome pour atteindre des objectifs complexes, en orchestrant des séquences d'actions, en utilisant des outils externes, en mémorisant des états intermédiaires et en s'adaptant dynamiquement aux résultats obtenus. Cette approche marque un changement de paradigme fondamental par rapport aux LLMs utilisés de manière statique pour la génération de texte : l'agent ne se contente plus de répondre à une requête, il planifie, exécute, observe et itère.

Définition académique :

Un agent IA est un système computationnel autonome qui perçoit son environnement via des capteurs ou des API, raisonne sur cet environnement à l'aide d'un modèle de décision (LLM, règles, planificateur symbolique), et agit sur cet environnement via des actionneurs ou des appels d'outils pour atteindre un objectif défini. Formellement, un agent est défini par le quadruplet (S, A, T, R) : espace d'états S , espace d'actions A , fonction de transition T , et fonction de récompense R .

7.1 Le cycle de raisonnement ReAct

Le paradigme ReAct (Reasoning and Acting), introduit par Yao et al. (2023), constitue le fondement de la plupart des frameworks agentiques modernes. ReAct entrelace le raisonnement du LLM (Thought) et l'exécution d'actions (Action) dans un cycle itératif :

Thought → **Action** → **Observation** → **Thought** → **Action** → ... → **Final Answer**

À chaque itération, le LLM génère d'abord une réflexion explicite sur l'état courant de la tâche (Thought), puis sélectionne et exécute une action parmi les outils disponibles (Action), et observe le résultat de cette action (Observation) avant de produire la prochaine réflexion. Ce cycle permet à l'agent de décomposer des tâches complexes en sous-étapes gérables et de corriger ses erreurs au fil de l'exécution.

7.2 Architectures multi-agents

Les systèmes multi-agents (MAS) étendent le paradigme agentique en faisant collaborer plusieurs agents spécialisés, chacun doté d'un rôle, d'une expertise et d'un ensemble d'outils distincts. Cette approche reproduit des dynamiques organisationnelles humaines (chef de projet, développeur, testeur, critique) au sein de systèmes d'IA :

- **Architecture Orchestrateur-Worker** : Les architectures hiérarchiques (Orchestrator-Worker) placent un agent orchestrateur responsable de la décomposition de la tâche globale et de la délégation aux agents spécialisés (workers). L'orchestrateur synthétise les résultats partiels pour produire la réponse finale. Cette architecture est utilisée par AutoGPT, BabyAGI et MetaGPT.
- **Architecture pair-à-pair** : Les architectures pair-à-pair (Peer-to-Peer) permettent aux agents de communiquer directement entre eux sans hiérarchie centrale. Chaque agent peut solliciter l'aide d'autres agents selon ses besoins. Cette approche, explorée par des frameworks comme AgentVerse et ChatDev, permet une collaboration plus organique mais est plus difficile à contrôler.

- Architecture de Debate : Les architectures de debate (Debate-based) font dialoguer plusieurs agents qui argumentent pour et contre différentes solutions, produisant par consensus une réponse de meilleure qualité que celle d'un agent unique. Cette approche améliore la robustesse et réduit les hallucinations sur des tâches de raisonnement complexe.

8. Frameworks Agentiques : État de l'Art

Framework	Éditeur	Paradigme	Forces	Maturité
LangChain / LangGraph	LangChain Inc.	Orchestration de chaînes et de graphes d'agents (LCEL)	Écosystème très riche, intégrations multiples, communauté massive, LangGraph pour workflows stateful complexes	Production — très mature
AutoGen (Microsoft)	Microsoft Research	Multi-agents conversationnels avec rôles définis	Excellente gestion du dialogue inter-agents, code execution sandbox intégré, flexible	Production — stable
CrewAI	Communauté open-source	Équipes d'agents avec rôles et tâches hiérarchiques	API intuitive, abstraction des rôles d'équipe, rapide à prototyper	Production — en croissance rapide
LlamaIndex Agents	LlamaData	Agents orientés connaissance et retrieval	Intégration native avec pipelines RAG complexes, très bon pour agents de Q&A sur documents	Production — mature pour RAG
Semantic Kernel	Microsoft	Planification et orchestration SDK multi-langage	Support natif C# et Python, intégration Azure OpenAI, plugins d'entreprise	Production — orienté entreprise
Haystack Agents	deepset	Pipelines NLP modulaires avec composants agentiques	Modulaire, open-source, excellent pour RAG+agents combinés, CLI et API	Production — stable

9. Mémorisation et Gestion d'État dans les Agents

La gestion de la mémoire constitue un défi central de l'IA agentique, particulièrement dans des applications comme la plateforme SENIORS où la continuité de l'expérience utilisateur est essentielle. Quatre types de mémoire sont distingués dans la littérature :

- Mémoire de travail (Working Memory) : correspond au contexte de la conversation courante, géré par la fenêtre de contexte du LLM. Limitée par la taille du contexte du modèle (de 4K à 1M tokens selon les modèles), elle ne persiste pas entre les sessions.
- Mémoire épisodique (Episodic Memory): stocke les souvenirs des interactions passées de l'utilisateur avec l'agent, permettant une personnalisation et une continuité à long terme. Des solutions comme MemGPT (Packer et al., 2023) ou des bases de données à embeddings permettent d'implémenter cette mémoire.

- Mémoire sémantique (Semantic Memory) : correspond à la base de connaissances du domaine, implémentée typiquement via une architecture RAG. Elle est partagée entre tous les utilisateurs et constitue la connaissance générale du système.
- Mémoire procédurale (Procedural Memory) : encode les comportements et les stratégies de l'agent sous forme de prompts système, de règles et de few-shot examples. Elle définit la personnalité et les compétences de l'agent.

10. Application de l'IA Agentique à la Plateforme SENIORS

Bien que l'IA agentique pleinement autonome dépasse les ambitions d'un prototype académique, certains patterns agentiques peuvent être intégrés de manière pragmatique dans la plateforme SENIORS pour enrichir l'expérience utilisateur :

Cas d'usage SENIORS	Pattern agentique	Description technique	Framework recommandé
Assistant de création d'annonce	Tool-use agent	L'agent utilise des outils pour interroger la base de données des annonces existantes, consulter les prix du marché local, vérifier la conformité légale des conditions proposées, puis génère une annonce optimisée	LangChain LCEL + tools
Facilitateur de matching	Sequential agent	L'agent analyse le profil du senior, interroge la base de candidats, filtre par critères, génère une synthèse de compatibilité pour chaque candidat, et rédige une recommandation personnalisée	LlamaIndex Agent
Support et résolution de conflits	Debate-based agent	Deux sous-agents (représentant le point de vue du senior et celui du locataire) débattent pour trouver un compromis, supervisés par un agent médiateur qui produit la recommandation finale	AutoGen
Détection proactive de l'isolement	Monitoring agent	Agent de surveillance qui analyse périodiquement les métriques d'usage d'un utilisateur (fréquence de connexion, messages envoyés, services utilisés) et déclenche des alertes ou des interventions si les indicateurs se dégradent	Haystack + cron scheduler

pour SENIORS : pour un prototype académique, commencer par un agent de tool-use simple utilisant LangChain avec 3 à 5 outils définis (recherche dans la base de données, génération

d'annonce, vérification de conformité, envoi de notification). Complexifier progressivement vers une architecture multi-agents en phase de production.

PARTIE IV : IA PREDICTIVE ET DECISIONNELLE

11. Fondements de l'IA Prédictive

L'intelligence artificielle prédictive désigne l'ensemble des techniques algorithmiques permettant de produire des estimations quantitatives sur des événements futurs ou des états non observés, à partir de données historiques et de patterns statistiques. Elle se distingue de l'IA générative (production de contenus nouveaux) et de l'IA agentique (exécution d'actions autonomes) par sa finalité première : réduire l'incertitude décisionnelle en fournissant des prédictions fondées sur des preuves empiriques.

Le champ de l'IA prédictive englobe un spectre large de techniques, allant des méthodes statistiques classiques (régression linéaire, modèles ARIMA pour les séries temporelles) aux approches modernes d'apprentissage automatique (Random Forest, Gradient Boosting, réseaux de neurones profonds) et aux architectures spécialisées pour des tâches spécifiques (systèmes de recommandation, détection d'anomalies, prévision temporelle).

11.1 Taxonomie des approches de Machine Learning prédictif

Famille d'algorithmes	Algorithmes représentatifs	Forces	Applications typiques
Méthodes ensemblistes basées sur les arbres	Random Forest, XGBoost, LightGBM, CatBoost	Robustesse aux valeurs aberrantes, interprétabilité partielle (feature importance), excellents sur données tabulaires, peu de preprocessing requis	Classification de risque, prédiction de churn, scoring de crédit, détection de fraude
Réseaux de neurones profonds (DNN)	MLP, ResNet tabulaire, TabNet, FT-Transformer	Capture de relations non-linéaires complexes, scalabilité aux grands volumes de données, transfer learning possible	Prédiction sur données complexes, embeddings de features catégorielles
Séries temporelles	ARIMA, Prophet (Meta), LSTM, Temporal Fusion Transformer	Modélisation explicite de la temporalité et de la saisonnalité	Prévision de demande, détection d'anomalies temporelles, prévision d'indicateurs de bien-être
Modèles linéaires régularisés	LASSO, Ridge, Elastic Net, Logistic Regression	Interprétabilité maximale, robustesse aux petits datasets, convergence rapide	Scoring de compatibilité interprétable, classification de profils

12. Systèmes de Recommandation : État de l'Art

Les systèmes de recommandation constituent la composante d'IA prédictive la plus centrale pour la plateforme SENIORS, dans la mesure où le matching intergénérationnel repose fondamentalement sur la capacité à prédire la compatibilité entre profils et à suggérer des mises en relation pertinentes. La littérature académique distingue quatre grandes familles d'approches :

12.1 Filtrage collaboratif (Collaborative Filtering)

Le filtrage collaboratif exploite les interactions passées entre utilisateurs et items pour inférer les préférences d'un utilisateur à partir du comportement d'utilisateurs similaires. Les deux variantes principales sont le filtrage collaboratif basé sur la mémoire (user-based et item-based) et le filtrage collaboratif basé sur les modèles (Matrix Factorization, SVD, NMF). Des architectures plus récentes basées sur des réseaux de neurones — Neural Collaborative Filtering (He et al., 2017), BERT4Rec (Sun et al., 2019) — ont considérablement amélioré les performances.

Limitation principale pour SENIORS : le problème du cold start — l'impossibilité de produire des recommandations pertinentes pour de nouveaux utilisateurs n'ayant pas encore d'historique d'interactions — est particulièrement aigu dans le contexte d'une plateforme naissante.

12.2 Filtrage basé sur le contenu (Content-Based Filtering)

Le filtrage basé sur le contenu recommande des items dont les attributs sont similaires à ceux des items appréciés par l'utilisateur dans le passé. Dans le contexte de la plateforme SENIORS, cette approche recommande des candidats à la cohabitation dont les profils présentent des caractéristiques compatibles avec les préférences déclarées du senior (horaires de vie, tolérance au bruit, appétences culinaires, activités partagées souhaitées). Cette approche présente l'avantage de ne pas souffrir du cold start et d'être naturellement interprétable.

12.3 Approches hybrides

Les systèmes hybrides combinent le filtrage collaboratif et le filtrage basé sur le contenu pour tirer parti des forces respectives de chaque approche tout en atténuant leurs faiblesses. Des architectures comme Wide & Deep (Google, 2016), DeepFM (Huawei, 2017) et Two-Tower Networks (utilisé par YouTube, Twitter, Pinterest) constituent l'état de l'art industriel. Pour la plateforme SENIORS, un système hybride progressif est recommandé : démarrage en filtrage basé sur le contenu (profil seul), puis enrichissement progressif par filtrage collaboratif à mesure que les données d'interactions s'accumulent.

12.4 Recommandation basée sur les graphes

Les Graph Neural Networks (GNN) appliqués aux systèmes de recommandation — NGCF (Wang et al., 2019), LightGCN (He et al., 2020) — modélisent les relations entre utilisateurs et items sous forme de graphes bipartites et propagent l'information le long des arêtes pour produire des recommandations. Cette approche est particulièrement adaptée aux contextes où les relations sociales entre utilisateurs (réseau de confiance, recommandations de pairs) sont des signaux pertinents.

13. Détection d'Anomalies et Modèles de Surveillance

Dans le contexte de la plateforme SENIORS, la détection d'anomalies revêt une double importance : la détection précoce de comportements suspects (fraude, abus) et la détection de signaux d'isolement ou de détresse chez les utilisateurs seniors.

13.1 Approches de détection d'anomalies

Approche	Algorithmes	Adapté pour	Pertinence pour SENIORS
Méthodes statistiques	Z-score, IQR, Grubbs test	Données unidimensionnelles, distributions connues	Détection d'anomalies dans les métriques d'usage (fréquence de connexion anormalement basse)
Isolation Forest	Isolation Forest (Liu et al., 2008)	Données multidimensionnelles, anomalies globales	Détection de profils frauduleux ou de comportements inhabituels multi-features
Autoencodeurs	VAE, AE profond	Données haute dimension, patterns complexes	Détection de dégradation du comportement numérique d'un senior (pattern d'usage inhabituel)
One-Class SVM	OCSVM, SVDD	Données déséquilibrées, peu d'exemples d'anomalies	Classification d'alertes sur profils suspects sans avoir besoin d'exemples de fraudes étiquetés

13.2 Indicateurs de surveillance du bien-être senior

En s'inspirant de la littérature sur la gérontechnologie (Ambient Assisted Living, AAL), la plateforme SENIORS peut définir un ensemble d'indicateurs comportementaux numériques (digital biomarkers) permettant de monitorer le bien-être des utilisateurs seniors :

Indicateur	Signal numérique mesuré	Valeur seuil d'alerte	Intervention suggérée
Fréquence de connexion	Nombre de sessions par semaine	Baisse > 50 % sur 2 semaines consécutives	Notification de rétention bienveillante, proposition d'activité
Taux de réponse aux messages	Délai moyen de réponse aux messages reçus	Non-réponse > 72 heures	Relance douce, vérification de bien-être par l'équipe de modération
Activité sur l'espace marketing	Publications et consultations hebdomadaires	Inactivité > 3 semaines	Suggestion de mise à jour du profil, recommandation de service
Évaluation de satisfaction	Score de satisfaction post-interaction	Score < 3/5 sur 2 interactions consécutives	Déclenchement d'un accompagnement humain

14. Application de l'IA Prédictive à la Plateforme SENIORS

L'intégration de l'IA prédictive dans la plateforme SENIORS s'articule autour de trois axes prioritaires, correspondant aux besoins fonctionnels identifiés lors de l'analyse des exigences :

14.1 Architecture du système de matching par IA prédictive

Le système de matching constitue le cœur de valeur ajoutée technique de la plateforme. Son architecture recommandée pour la plateforme SENIORS est la suivante :

- Phase 1 (prototype) : Filtrage basé sur le contenu : les profils des seniors et des candidats locataires sont représentés par des vecteurs de features (âge, ville, horaires, tolérance au bruit, préférences alimentaires, activités souhaitées, conditions sociales). Un score de similarité cosinus est calculé pour chaque paire. Ce système est opérationnel dès le premier utilisateur.
- Phase 2 (croissance) : Enrichissement par un modèle de gradient boosting : un modèle XGBoost ou LightGBM est entraîné sur les retours utilisateurs (cohabitations réussies vs. échouées) pour apprendre des patterns de compatibilité au-delà de la simple similarité. Les features incluent des interactions entre variables (ex. : senior nocturne + locataire matinal → incompatibilité forte).
- Phase 3 (maturité) : Hybridation avec filtrage collaboratif : à partir d'un volume suffisant d'utilisateurs actifs (minimum 500 à 1 000), un modèle de filtrage collaboratif est ajouté pour capturer des patterns de préférence latents non explicitement déclarés dans les profils.

14.2 Métriques d'évaluation du système de recommandation

Métrique	Formule / Description	Valeur cible pour SENIORS	Interprétation
Précision@k	Proportion de recommandations pertinentes parmi les k premières	> 0,70 pour k=5	Qualité des suggestions les plus visibles à l'utilisateur
Rappel@k	Proportion de bons matchs effectivement recommandés parmi les k premiers	> 0,60 pour k=10	Capacité à ne pas manquer de bonnes correspondances
NDCG@k (Normalized Discounted Cumulative Gain)	Mesure de la qualité du classement, pondérée par la position	> 0,75	Pertinence globale du classement des recommandations
Coverage	Proportion du catalogue couverte par les recommandations	> 0,30	Diversité des recommandations, évite les effets de bulle
Satisfaction utilisateur (proxy)	Taux d'acceptation des recommandations (clics, contacts initiés)	> 25 % de taux de clic	Validation terrain de la pertinence perçue par les utilisateurs

PARTIE V : SYNTHÈSE ET ARCHITECTURE IA RECOMMANDÉE POUR SENIORS

15. Architecture IA Intégrée pour la Plateforme SENIORS

La synthèse de cette veille technologique permet de proposer une architecture IA intégrée pour la plateforme SENIORS, combinant de manière cohérente et progressive les quatre dimensions technologiques explorées. Cette architecture est conçue pour être réaliste dans le cadre d'un stage académique, tout en posant les fondations d'une évolution vers un système de production scalable.

15.1 Architecture en couches

Couche	Composants technologiques	Rôle fonctionnel	Technologies retenues
Couche de données	PostgreSQL, ChromaDB, Redis (cache)	Stockage des profils utilisateurs, des documents RAG indexés, et du cache des recommandations fréquentes	PostgreSQL (données structurées), ChromaDB (vecteurs), Redis (sessions)
Couche d'embedding et indexation	Modèle d'embedding multilingue, pipeline d'ingestion RAG	Transformation des profils et des documents en représentations vectorielles denses	paraphrase-multilingual-mpnet-base-v2 (HuggingFace), LangChain document loaders
Couche de recommandation (IA prédictive)	Content-based filter → XGBoost → modèle hybride	Calcul des scores de compatibilité et génération des recommandations de matching	scikit-learn, XGBoost, LightFM (hybride)
Couche RAG	Base vectorielle + re-ranker + LLM	Réponse aux questions factuelles, support utilisateur, génération d'annonces fondées sur des données vérifiables	ChromaDB + ms-marco re-ranker + Mistral 7B (Ollama)
Couche agentique	Agent tool-use orchestrateur + outils définis	Orchestration des workflows complexes (création d'annonce assistée, matching guidé)	LangChain LCEL + 4–5 outils custom
Couche LLM conversationnelle	Chatbot senior-friendly avec mémoire	Interface de dialogue avec l'utilisateur, guidage, explication des recommandations	Mistral 7B + LangChain ConversationBufferMemory + ChromaDB (mémoire long terme)
Couche de surveillance (IA prédictive)	Modèle de détection d'anomalies + alertes	Détection proactive de l'isolement et des comportements suspects	Isolation Forest (scikit-learn) + cron job + système d'alertes

15.2 Feuille de route technologique par phase de développement

Phase du projet	Technologies IA prioritaires	Justification	Complexité
Phase 1 — Prototype (Stage PFE)	Content-based filtering (scikit-learn) + RAG simple (ChromaDB + Mistral 7B via Ollama) + Chatbot basique (LangChain + mémoire)	Fonctionnalités IA de base opérationnelles dès le lancement, zéro coût cloud, déploiement local	Faible à moyenne
Phase 2 — Beta (6–12 mois post-stage)	Ajout de XGBoost pour le matching + fine-tuning LoRA sur Mistral pour le domaine SENIORS + RAG avancé avec re-ranking	Amélioration des performances avec les premières données réelles, personnalisation accrue	Moyenne
Phase 3 — Production (> 12 mois)	Système hybride recommandation + LLM agentique (orchestrateur multi-outils) + détection d'anomalies + monitoring continu	Plateforme IA complète et scalable, capable de gérer des milliers d'utilisateurs actifs	Élevée

16. Analyse Comparative des Technologies et Recommandations Finales

Dimension technologique	Technologie retenue	Alternative écartée	Justification du choix
LLM de base (chatbot)	Mistral 7B (open-source, Ollama local)	GPT-4o (API propriétaire)	Coût nul, déploiement local RGPD-compliant, francophone, suffisant pour le prototype
LLM haute performance (génération complexe)	Claude 3.5 Sonnet (API, usage ponctuel)	GPT-4o	Supériorité sur les tâches de raisonnement long et de following d'instructions précis
Architecture RAG	RAG standard + re-ranking	Self-RAG, RAPTOR	Complexité maîtrisable pour un projet académique, performances suffisantes pour les cas d'usage identifiés
Base vectorielle	ChromaDB	Pinecone, Weaviate	Gratuité totale, déploiement local simple, API Python intuitive, suffisant pour le volume de données du prototype
Système de recommandation	Content-based → hybride progressif	Filtrage collaboratif pur	Contourne le cold start, opérationnel dès le premier utilisateur, évolutif
Framework agentique	LangChain LCEL	AutoGen, CrewAI	Maturité maximale, documentation abondante, intégration native avec RAG et outils custom
Détection d'anomalies	Isolation Forest (scikit-learn)	Autoencodeur VAE	Robustesse sans données étiquetées d'anomalies, implémentation simple, interprétabilité partielle

CONCLUSION — SYNTHÈSE DE LA VEILLE ET PERSPECTIVES

Cette veille technologique a permis de dresser un panorama complet et actualisé des technologies d'intelligence artificielle les plus pertinentes pour le projet SENIORS, en couvrant quatre dimensions complémentaires : les Grands Modèles de Langage (LLM), la Retrieval-Augmented Generation (RAG), l'IA agentique et l'IA prédictive et décisionnelle.

Plusieurs enseignements majeurs se dégagent de cette analyse :

Maturité des LLM open-source : L'écosystème des LLM open-source a atteint un niveau de maturité suffisant pour envisager le déploiement de solutions performantes sans dépendance aux APIs propriétaires coûteuses. LLaMA 3.1 et Mistral 7B constituent des choix solides pour un projet académique, combinant performances, gratuité et conformité réglementaire.

La RAG comme colonne vertébrale de la connaissance : La RAG s'est imposée comme l'architecture de référence pour doter les LLM d'une base de connaissances spécialisée et actualisable sans réentraînement. Son application à la plateforme SENIORS permet de garantir la pertinence factuelle des réponses de l'assistant conversationnel et de réduire significativement les hallucinations.

L'IA agentique : la frontière la plus dynamique : L'IA agentique représente la frontière technologique la plus dynamique de 2024–2025, avec l'émergence de frameworks matures (LangChain LangGraph, AutoGen, CrewAI) permettant de déployer des agents autonomes dans des applications réelles. Des patterns agentiques simples (tool-use, séquentiels) peuvent être intégrés dès le prototype pour enrichir l'expérience utilisateur.

L'IA prédictive : valeur dès le prototype : L'IA prédictive, et en particulier les systèmes de recommandation, constitue le levier technologique le plus directement valorisable pour le matching intergénérationnel de la plateforme SENIORS. L'approche progressive — démarrage en filtrage basé sur le contenu, évolution vers des modèles hybrides — permet de livrer de la valeur dès la phase de prototype tout en préparant la montée en puissance.

En conclusion, le projet SENIORS bénéficie d'un contexte technologique particulièrement favorable : les outils open-source de qualité sont abondants, les frameworks d'intégration sont matures et bien documentés, et les techniques légères d'adaptation des modèles (LoRA, QLoRA, RAG) permettent d'obtenir des résultats de qualité sans ressources computationnelles prohibitives. L'enjeu principal n'est plus la disponibilité des technologies, mais la qualité et la quantité des données spécifiques au domaine, ainsi que la rigueur de l'évaluation des systèmes développés.

« Nous vivons un moment historique où les technologies d'IA les plus avancées sont accessibles à des équipes de deux ou trois personnes avec un budget minimal. La barrière à l'entrée n'est plus technologique — elle est épistémique : savoir quelles techniques choisir, comment les évaluer rigoureusement et comment les intégrer de manière éthique dans des produits qui créent une valeur réelle pour les utilisateurs. » — Andrej Karpathy (2024)

RÉFÉRENCES BIBLIOGRAPHIQUES

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS 2020*.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... & Chen, W. (2021). LoRA: Low-Rank Adaptation of Large Language Models. *ICLR 2022*.
- Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. *NeurIPS 2023*.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. *ICLR 2023*.
- He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T. S. (2017). Neural Collaborative Filtering. *WWW 2017*.
- Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2023). Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. *ICLR 2024*.
- Sarathi, P., Abdullah, S., Tiwari, A., Ghosh, P., Goldie, A., & Manning, C. D. (2024). RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval. *ICLR 2024*.
- Gao, L., Ma, X., Lin, J., & Callan, J. (2022). Precise Zero-Shot Dense Retrieval without Relevance Labels (HyDE). *ACL 2023*.
- Packer, C., Fang, V., Patil, S. G., Dhari, K., Wooders, A., & Gonzalez, J. E. (2023). MemGPT: Towards LLMs as Operating Systems. *arXiv:2310.08560*.
- Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation Forest. *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*.
- He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. *SIGIR 2020*.
- Grand View Research. (2023). Age Tech Market Size, Share & Trends Analysis Report. San Francisco: Grand View Research.
- Organisation Mondiale de la Santé. (2021). Social Isolation and Loneliness in Older People: Advocacy Brief. Genève: OMS.
- Haut-Commissariat au Plan du Maroc. (2020). Projections de la population et des ménages 2014–2050. Rabat: HCP.